

1. Contexto de Negócios e Perguntas

Os filmes de terror representam um gênero consolidado na indústria cinematográfica, com uma ampla variedade de produções ao longo das décadas e um público interessado em diferentes subgêneros e estilos. O gênero também apresenta características particulares em relação à produção e ao desempenho comercial de seus filmes. Historicamente, algumas produções de destaque foram realizadas com orçamentos relativamente baixos, enquanto lançamentos mais recentes passaram a contar, em determinados casos, com investimentos mais elevados.

Diante desse contexto, o presente trabalho tem como objetivo estruturar os dados e realizar uma análise de filmes de terror para identificar padrões relacionados ao desempenho das produções. Para isso, foram analisados aspectos como popularidade, avaliação do público, orçamento e vendas. Ao fim do projeto, busca-se responder os seguintes questionamentos:

1. Ranqueamento da performance dos filmes.

- a) Quais os 10 filmes mais populares?
- b) Quais os 5 filmes mais bem avaliados?
- c) Quais os 5 filmes com maior orçamento?

2. Evolução do desempenho dos filmes.

- a) Qual a quantidade de filmes por década?
- b) Como foi a evolução do orçamento médio por década?
- c) Como foi a evolução da receita média por década?

Para atender às perguntas propostas, foi necessário realizar a busca por dados relacionados a filmes de terror. Para isso, foi utilizado um conjunto de dados disponibilizado na plataforma Kaggle por Evan Gower, contendo informações sobre filmes do gênero terror produzidos desde a década de 1950. O conjunto de dados está disponível em: <https://www.kaggle.com/datasets/evangower/horror-movies>, conforme apresentado na Figura 1.



EVAN GOWER · UPDATED 4 YEARS AGO

Horror Movies

Explore horror movies dating back to the 1950s

Data Card

Code (6)

Discussion (2)

Suggestions (0)

About Dataset

 Explore this horror movies dataset with films dating back to the 1950s.

The dataset was extracted from The Movie Database via the tmdb API using R httr by Tanya Shapiro. There are ~32K movie records in this dataset.

You can view my visualization I created in the discussion area.

[Image](#) from Unsplash

horror_movies.csv (14.42 MB)



Download

Download via kagglehub

New to Kaggle API? Here's how to [set up your API keys.](#)

```
import kagglehub

# Download latest version
path = kagglehub.dataset_download("evangower/horror-movies")

print("Path to dataset files:", path)
```

Download dataset as zip (6 MB)

Export metadata as Croissant

Tags

Movies and TV Shows

Data Explorer

Version 1 (14.42 MB)

Figura 1: Dados no Kaggle.

Os dados foram baixados da plataforma em formato ZIP e, posteriormente, extraídos, obtendo-se o arquivo `horror_movies.csv`. E posteriormente carregado em ambiente de nuvem para ser utilizado nas etapas subsequentes do projeto.

2. Carga de Dados

No ambiente do Databricks foi selecionado a opção “New” seguido de “Add or upload data”, em seguida, foi selecionado a opção “Create or modify table from files” e feito o upload do arquivo “horror_movies.csv”, conforme Figura 2, sendo criado a tabela horror_movies. Na Aba “Catalog” é possível visualizar a tabela criada. Adicionalmente, foi adicionado comentários em algumas colunas e descrição da tabela a partir do auxílio da IA integrada ao ambiente, conforme Figura 3.

Add data >

Create or modify table from files

Serverless Starter Warehouse

horror_movies.csv uploaded 14.42MB

Create new table

Preview mode

Catalog

Schema

Table name

workspace

default

horror_movies

Advanced attributes

Previewing 50 rows, 20 columns

id	original_title	title	original_language	overview	tagline	release
760161	Orphan: First Kill	Orphan: First Kill	en	After escaping from an Estonian...	There's always been somethin...	2022-07-27
760741	Beast	Beast	en	A recently widowed man and ...	Fight for family.	2022-08-11
882598	Smile	Smile	en	After witnessing a bizarre, trau...	Once you see it, it's too late.	2022-09-23
756999	The Black Phone	The Black Phone	en	Finney Blake, a shy but clever ...	Never talk to strangers.	2022-06-22
772450	Presencias	Presences	es	A man who loses his wife and ...	NA	2022-09-07
1014226	Sonríe	Sonríe	es	NA	NA	2022-08-18
717728	Jeepers Creepers: Reborn	Jeepers Creepers: Reborn	en	Forced to travel with her boyfr...	Evil Rides Again	2022-09-15
762504	Nope	Nope	en	Residents in a lonely gulch of i...	What's a bad miracle?	2022-07-20
927341	Hunting Ava Bravo	Hunting Ava Bravo	en	Billionaire sportsman Buddy Ki...	"If I die, you die"	2022-04-01

Cancel

Create table

Figura 2: Criando tabela de dados.

Catalog Explorer > workspace > default >

horror_movies

Open in a dashboard

Share

Create

Overview

Sample Data

Details

Permissions

Policies

History

Lineage

Insights

Quality

Description

The table contains information about horror movies, including their titles, original language, release dates, and various metadata such as budgets, revenues, and popularity scores. This data can be used to analyze trends in horror films, assess their financial performance, and understand audience preferences based on ratings and summaries.

Filter columns...

Column	Type	Popularity	Comment	Tags	Column masking ⓘ	
id	bigint		Unique identifier for each movie, used to differentiate between different entries in the dataset.			
original_title	string		The title as it was released in its original version, which may differ from the current title.			

Figura 3: Adicionando descrição a tabela e colunas.

3. Modelagem e Catálogo de Dados

Para a realização da análise, foi utilizada uma tabela única no formato flat table (tabela plana). Tendo assim um modelo Flat. Essa abordagem foi adotada porque o conjunto de dados já disponibiliza, em uma mesma estrutura, as informações necessárias para responder aos questionamentos propostos, não sendo necessária a integração ou importação de dados provenientes de outras fontes.

A tabela contém registros de filmes e seus respectivos atributos, incluindo informações como título, data de lançamento, popularidade, avaliação, orçamento e receita. Dessa forma, foi possível realizar as análises propostas diretamente sobre a tabela, aplicando os tratamentos e filtros necessários aos dados. A utilização de uma tabela plana também simplifica o processo de análise, uma vez que não há necessidade de estabelecer relacionamentos entre diferentes tabelas ou realizar operações de junção (joins) para obter os indicadores utilizados no estudo.

Na Figura 4, Figura 5 e Figura 6 apresenta-se algumas colunas da tabela horror_movies, com o tipo de variável e descrição.

Column	Type	Popularity	Comment	Tags
id	bigint		Unique identifier for each movie, used to differentiate between different entries in the dataset. 	Add tag
original_title	string		The title as it was released in its original version, which may differ from the current title.	
title	string		The title currently recognized and used for the movie, which may have been altered for different regions or releases.	
original_language	string		The language in which the film was originally produced, providing context for its cultural origin.	
overview	string		A brief synopsis of the film's plot, offering insights into the story and themes of the movie.	
tagline	string		A memorable phrase or slogan associated with the film, often used in marketing to capture the essence of the story.	

Figura 4: Descrição das colunas (Parte 1).

release_date	date		The official date when the film was released to the public, significant for understanding its market timing. 
poster_path	string		The file path to the film's promotional poster image, useful for visual representation in analyses or presentations.
popularity	double		A score indicating how popular the movie is among audiences, based on various metrics and trends.
vote_count	bigint		The total number of user votes the film has received, reflecting its level of audience engagement.
vote_average	double		The average rating given to the movie by viewers, providing an overall assessment of audience reception.
budget	double		The estimated cost of producing the film, critical for analyzing its financial success relative to its earnings.
revenue	double		The total income generated by the film, often used to evaluate its commercial performance against the budget.

Figura 5: Descrição das colunas (Parte 2).

runtime	bigint		The total duration of the film in minutes, which can influence audience viewing preferences.
status	string		The current distribution status of the film, indicating whether it is released, upcoming, or in production.
adult	boolean		A boolean value indicating whether the film is intended for adult audiences, important for age-based content classification.
backdrop_path	string		The file path to a larger background image from the film, often used for promotional purposes in various media.
genre_names	string		A list of genres that categorize the film, helping to understand its thematic elements and audience targeting.
collection	string		Information about a collection of related films that this movie is a part of, useful for analyzing franchises or sequels.
collection_name	string		The name of the collection to which this movie belongs, providing context for its placement within a larger thematic group.

Figura 6: Descrição das colunas (Parte 3).

Como a tabela não apresenta todos requisitos descritos no problema, foi desenvolvido uma tabela auxiliar como catálogo de dados (Tabela 1).

Tabela 1 – Catálogo de Dados.


Coluna	Descrição	Tipo de Dado	Domínio	Linhagem dos dados
id	Identificador único do filme.	Número inteiro	Valores inteiros positivos. No conjunto analisado: 17 a 1.033.095.	Origem: horror_movies.csv. Sem transformação ou junção.
original_title	Título original do filme no lançamento.	Texto	Texto livre. Pode conter caracteres de diferentes	Origem: horror_movies.csv. Sem transformação ou

			idiomas.	junção.
title	Título utilizado para identificação do filme no conjunto de dados.	Texto	Texto livre.	Origem: horror_movies.csv. Sem transformação ou junção.
original_language	Código do idioma original do filme.	Texto	Códigos de idioma presentes na fonte.	Origem: horror_movies.csv. Sem transformação ou junção.
overview	Sinopse ou descrição resumida do filme.	Texto	Texto livre. Pode apresentar valores vazios/nulos na fonte original.	Origem: horror_movies.csv. Sem transformação ou junção.
tagline	Frase que identifica o filme.	Texto	Texto livre. Pode apresentar valores vazios/nulos na fonte original.	Origem: horror_movies.csv. Sem transformação ou junção.
release_date	Data de lançamento do filme.	Data	Datas entre 1950-01-01 e 2022-12-31 no conjunto analisado.	Origem: horror_movies.csv. Sem transformação ou junção.
poster_path	Caminho para poster promocional.	Texto	Link.	Origem: horror_movies.csv. Sem transformação ou junção.
popularity	Indicador de popularidade atribuído ao filme pela fonte de dados.	Decimal	Valores não negativos. No conjunto analisado: 0,0 a 5.088,584.	Origem: horror_movies.csv. Sem transformação ou junção.
vote_count	Quantidade de votos utilizados para compor a avaliação do filme.	Número inteiro	Valores inteiros não negativos. No conjunto analisado: 0 a 16.900.	Origem: horror_movies.csv. Sem transformação ou junção.
vote_average	Média das avaliações atribuídas ao filme.	Decimal	Escala de 0 a 10.	Origem: horror_movies.csv. Sem transformação ou junção.
budget	Orçamento estimado utilizado na produção do filme.	Decimal	Valores não negativos. No conjunto analisado: US\$ 0 a US\$ 200.000.000.	Origem: horror_movies.csv. Sem transformação ou junção.
revenue	Receita gerada pelo filme.	Decimal	Valores não negativos. No conjunto analisado: US\$ 0 a US\$ 701.842.551.	Origem: horror_movies.csv. Sem transformação ou junção.
runtime	Tempo de filme em minutos.	Número inteiro	Valores não negativos.	Origem: horror_movies.csv.

				Sem transformação ou junção.
status	Situação do filme em relação ao seu processo de produção ou lançamento.	Texto	Released, Post Production, In Production e Planned.	Origem: horror_movies.csv. Sem transformação ou junção.
adult	Indicador se o filme é para audiência adulta.	Booleano	Valores de Verdadeiro ou Falso.	Origem: horror_movies.csv. Sem transformação ou junção.
backdrop_path	Caminho para imagem de fundo promocional do filme.	Texto	Link.	Origem: horror_movies.csv. Sem transformação ou junção.
genre_names	Lista de gêneros que categorizam o filme.	Texto	Texto livre. Pode apresentar valores vazios/nulos na fonte original.	Origem: horror_movies.csv. Sem transformação ou junção.
collection	Informação de uma coleção de filmes relacionados.	Texto	Pode apresentar valores vazios/nulos na fonte original. Com valores numéricos (Provavelmente chave estrangeira).	Origem: horror_movies.csv. Sem transformação ou junção.
collection_name	Nome da coleção que o filme pertence.	Texto	Texto livre. Pode apresentar valores vazios/nulos na fonte original.	Origem: horror_movies.csv. Sem transformação ou junção.

4. Pipeline de Dados

Para verificar a persistência da tabela na plataforma, além da visualização no Catalog, foi criado um notebook “Camada Bronze” com uma query simples que seleciona todos os dados da tabela (Figura 7).



The screenshot shows a Databricks notebook titled "Camada Bronze". The code cell contains a SQL query: `%sql SELECT * FROM horror_movies`. Below the code, the results are displayed in a table with 5 columns: `id`, `original_title`, `title`, `original_language`, and `overview`. The table contains 15 rows of data, including movies like "Orphan: First Kill", "Beast", "Smile", "The Black Phone", "Presencias", "Sonrie", "Jeepers Creepers: Reborn", "Nope", "Hunting Ava Bravo", "X", "The Exorcism of God", "The Jack in the Box: Awakening", "Torn Hearts", and "The Cellar". The bottom of the interface indicates "3,775+ rows", "Truncated data", and "44.480s runtime".

	id	original_title	title	original_language	overview
1	760161	Orphan: First Kill	Orphan: First Kill	en	> After escaping from an Estonian psychiatric facility, Leena Klammer travels to America by impersonati
2	760741	Beast	Beast	en	> A recently widowed man and his two teenage daughters travel to a game reserve in South Africa. How
3	882598	Smile	Smile	en	> After witnessing a bizarre, traumatic incident involving a patient, Dr. Rose Cotter starts experiencing fi
4	756999	The Black Phone	The Black Phone	en	> Finney Blake, a shy but clever 13-year-old boy, is abducted by a sadistic killer and trapped in a sound,
5	772450	Presencias	Presences	es	A man who loses his wife and goes to seclude himself in a cabin in the woods, where strange things hap
6	1014226	Sonrie	Sonrie	es	NA
7	717728	Jeepers Creepers: Reborn	Jeepers Creepers: Reborn	en	> Forced to travel with her boyfriend to a horror festival, Laine begins to experience disturbing visions z
8	762504	Nope	Nope	en	Residents in a lonely gulch of inland California bear witness to an uncanny, chilling discovery.
9	927341	Hunting Ava Bravo	Hunting Ava Bravo	en	> Billionaire sportsman Buddy King unwinds by hunting human captives on his remote mountain estate
10	760104	X	X	en	> In 1979, a group of young filmmakers set out to make an adult film in rural Texas, but when their recl
11	836225	The Exorcism of God	The Exorcism of God	en	> An American priest working in Mexico is considered a saint by many local parishioners. However, due
12	801071	The Jack in the Box: Awakening	The Jack in the Box: Awakening	en	> When a vintage Jack-in-the-box is opened by a dying woman, she enters into a deal with the demon
13	852830	Torn Hearts	Torn Hearts	en	> A promising up-and-coming country duo seek out the secluded mansion of their idol Harper Dutch, i
14	758724	The Cellar	The Cellar	en	> When Keira Woods' daughter mysteriously vanishes in the cellar of their new house in the country, sh
15					

Figura 7: Consulta inicial a tabela "horror_movies".

A partir da chamada é possível ver que o comando funciona corretamente e que os dados podem ser visualizados.

Para a implementação do pipeline de dados, o processo foi estruturado em diferentes notebooks, nos quais foram aplicados filtros e transformações preliminares antes da etapa de análise final. A Figura 8 apresenta a ordem de execução dos notebooks, que serão detalhados nas seções seguintes.




Figura 8: Ordem de execução dos notebooks.

5. Qualidade de Dados

Durante a análise dos dados foi visto que muitas colunas não eram necessárias para avaliação das questões levantadas. Por conta disto, optou-se por retirar as colunas desnecessárias para o estudo. Adicionalmente, foram removidas as linhas com dados vazios para melhorar a qualidade dos dados. Os procedimentos citados foram implementados no notebook chamado de “Camada Silver”.

Foi observado que os dados já apresentavam uma qualidade boa e que poucos ajustes eram necessários. Foi avaliado a quantidade de registros antes e após as filtrações e realizado a persistência da nova tabela com o nome “horror_movies_processed” (Figura 9). Os resultados após execução são apresentados na Figura 10.



```
from pyspark.sql.functions import *

df = spark.table("workspace.default.horror_movies")

print("Registros originais:", df.count())

# Remover colunas que não serão utilizadas
colunas_remover = [
    "tagline",
    "poster_path",
    "runtime",
    "adult",
    "backdrop_path",
    "genre_names",
    "collection",
    "collection_name",
    "overview",
    "original_title",
    "status"
]

df_filtered = df.drop(*colunas_remover)

# Remover linhas que possuem valores nulos nas colunas restantes
df_filtered = df_filtered.dropna()

print("Registros após tratamento:", df_filtered.count())

# Exibir os dados
display(df_filtered)

# Criar a nova tabela
df_filtered.write.mode("overwrite").saveAsTable(
    "workspace.default.horror_movies_processed"
)
```

Figura 9: Aplicação de filtro na tabela horror_movies.

> 2 dataframes: df, df_filtered
Registros originais: 32754
Registros após tratamento: 32456

	id	title	original_language	release_date	popularity	vote_count	vote_average	budget	revenue
1	760161	Orphan: First Kill	en	2022-07-27	5088.584	902	6.9	0	9572765
2	760741	Beast	en	2022-08-11	2172.338	584	7.1	0	56000000
3	882598	Smile	en	2022-09-23	1863.628	114	6.8	17000000	45000000
4	756999	The Black Phone	en	2022-06-22	1071.398	2736	7.9	18800000	161000000
5	772450	Presences	es	2022-09-07	1020.995	83	7	0	0
6	1014226	Sonrie	es	2022-08-18	939.712	1	1	0	0
7	717728	Jeepers Creepers: Reborn	en	2022-09-15	821.605	125	5.8	20000000	2892594
8	762504	Nope	en	2022-07-20	733.112	1684	7	68000000	170800000
9	927341	Hunting Ava Bravo	en	2022-04-01	574.832	73	6.5	0	0
10	760104	X	en	2022-03-17	543.67	1035	6.8	10000000	14257609
11	836225	The Exorcism of God	en	2022-03-11	537.252	637	7.3	1500000	0
12	801071	The Jack in the Box: Awakening	en	2022-02-24	527.579	157	6.4	0	0
13	852830	Torn Hearts	en	2022-05-20	525.876	39	6.1	0	0
14	758724	The Cellar	en	2022-03-25	513.757	257	6.6	0	0
15	816952	My Best Friend's Exorcism	en	2022-09-29	501.921	43	6.1	0	0

10,000+ rows Truncated data 13.838s runtime Refreshed 3m ago

Figura 10: Resultado após aplicação dos filtros e limpeza.

Após tratamento, no notebook “Camada Gold” é selecionado a nova tabela ajustada (com limite de 10 registros) para verificação da persistência da tabela (Figura 11). Percebe-se também que a tabela já apresenta uma estrutura pronta para realização da etapa de análise.

Home Camada Bronze Camada Silver Camada Gold

File Edit View Run Help Python Full Last edit was 5 minutes ago Run all Serverless Schedule

SQL

```
%sql
SELECT * FROM horror_movies_processed LIMIT 10
```

See performance (1) Checked for improvements

	id	title	original_language	release_date	popularity	vote_count	vote_average	budget	revenue
1	760161	Orphan: First Kill	en	2022-07-27	5088.584	902	6.9	0	9572765
2	760741	Beast	en	2022-08-11	2172.338	584	7.1	0	56000000
3	882598	Smile	en	2022-09-23	1863.628	114	6.8	17000000	45000000
4	756999	The Black Phone	en	2022-06-22	1071.398	2736	7.9	18800000	161000000
5	772450	Presences	es	2022-09-07	1020.995	83	7	0	0
6	1014226	Sonrie	es	2022-08-18	939.712	1	1	0	0
7	717728	Jeepers Creepers: Rebo...	en	2022-09-15	821.605	125	5.8	20000000	2892594
8	762504	Nope	en	2022-07-20	733.112	1684	7	68000000	170800000
9	927341	Hunting Ava Bravo	en	2022-04-01	574.832	73	6.5	0	0
10	760104	X	en	2022-03-17	543.67	1035	6.8	10000000	14257609

10 rows 10.268s runtime Refreshed 4m ago

This result is stored as `_sql1df` and can be used in other Python and SQL cells.

Figura 11: Consulta a tabela criada "horror_movies_processed".

6. Análise de Dados

Foi desenvolvido o notebook “Análise”, utilizado como ambiente para a execução das etapas de exploração e análise dos dados. Nesse notebook, foram implementadas consultas utilizando SQL e PySpark, permitindo realizar a extração, transformação, agregação e análise dos dados armazenados no banco de dados. As consultas e análises desenvolvidas tiveram como objetivo responder às questões definidas, gerando os resultados e indicadores necessários para a avaliação do conjunto de dados.

Considerando as perguntas relacionadas ao “Ranqueamento da performance dos filmes.”:

a) Quais os 10 filmes mais populares?




Figura 12: Consulta de filmes mais populares.

Conforme Figura 12, a consulta permite identificar os filmes com maior nível de popularidade entre os usuários da plataforma de origem dos dados. A análise desse indicador pode ser utilizada para apoiar diferentes aplicações, como a geração de recomendações com base na popularidade dos títulos ou a identificação de filmes em destaque para divulgação em plataformas especializadas em filmes de terror e em portais de notícias. Dessa forma, o indicador de popularidade pode contribuir para a identificação de tendências e para a definição de conteúdos a serem destacados aos usuários.

b) Quais os 5 filmes mais bem avaliados?

The screenshot shows a SQL query interface with the title "b) Quais os 5 filmes mais bem avaliados?". The query is: `SELECT title, vote_average FROM horror_movies_processed ORDER BY vote_average DESC LIMIT 5;`. The results table has two columns: "title" and "vote_average". The top 5 movies are listed with a vote average of 10 each.

	title	vote_average
1	Spookiz: The Mov...	10
2	Feed Me	10
3	Halloween Ends	10
4	The Nightmare	10
5	Exorcist Vengeance	10

5 rows 1.404s runtime Refreshed Yesterday

Figura 13: Consulta dos filmes mais bem avaliados.

De forma similar à análise de popularidade, a avaliação dos filmes com maiores notas atribuídas pelos usuários permite identificar os títulos mais bem avaliados na plataforma (Figura 13). Esse indicador pode ser utilizado como critério para a geração de recomendações, possibilitando destacar filmes com melhor desempenho nas avaliações dos usuários e auxiliar na identificação de conteúdos de maior aceitação pelo público.

c) Quais os 5 filmes com maior orçamento?

The screenshot shows a SQL query interface with the title "c) Quais são os 5 filmes com maior orçamento?". The query is: `SELECT title, budget FROM horror_movies_processed ORDER BY budget DESC LIMIT 5;`. The results table has two columns: "title" and "budget". The top 5 movies are listed with their respective budgets.

	title	budget
1	Messengers	200000000
2	World War Z	200000000
3	Van Helsing	160000000
4	The Wolfman	150000000
5	The Meg	150000000

5 rows 2.249s runtime Refreshed Yesterday

Figura 14: Consulta dos filmes com maior orçamento.

A análise dos filmes com maiores orçamentos permite identificar as produções que receberam maior volume de investimento financeiro. Esse indicador pode ser utilizado para destacar filmes de maior escala de produção, considerando aspectos como investimentos em efeitos especiais, elenco, cenografia, produção e demais recursos envolvidos na realização cinematográfica.

Por sua vez, considerando a “Evolução do desempenho dos filmes”, tem-se a avaliação dos seguintes critérios:

a) Qual a quantidade de filmes por década?




Figura 15: Consulta da quantidade de filmes por década.

A consulta para obtenção da quantidade de filmes foi desenvolvida utilizando PySpark. Inicialmente, foi criada uma nova coluna denominada “decade”, calculada a partir do ano de lançamento dos filmes, obtido pelo campo `release_date`. Em seguida, os registros foram agrupados por década e contabilizados, resultando na criação da coluna “`number_of_movies`”, que representa a quantidade de filmes lançados em cada período (Figura 15).




Figura 16: Visualização da quantidade de filmes por década.

Os resultados também podem ser visualizados por meio do recurso “Visualization”, disponibilizado no próprio ambiente do Databricks. Para essa visualização, foi definido o campo decade como eixo X e o campo number_of_movies como eixo Y, utilizando o formato de gráfico de barras (Bar). A representação gráfica facilita a análise da distribuição dos lançamentos ao longo das décadas. Com base nos resultados obtidos, observa-se que a década de 2010 apresenta a maior quantidade de filmes registrados na base de dados analisada (Figura 16).

b) Como foi a evolução do orçamento médio por década?




Figura 17: Consulta da evolução do orçamento médio por década.

Para a análise da evolução do orçamento, também foi criada a coluna “decade”, utilizada para agrupar os filmes de acordo com a década de lançamento. Durante as consultas iniciais, verificou-se a presença de uma quantidade significativa de registros com orçamento igual a zero. Considerando que esses valores podem representar filmes para os quais a informação de orçamento não estava disponível, esses registros foram desconsiderados da análise, evitando que valores nulos ou não informados distorcessem o cálculo da média.

Após a aplicação desse filtro, foi calculado o orçamento médio por década, armazenado no campo “average_budget”. Adicionalmente, foi contabilizada a quantidade de filmes considerados em cada década, levando em conta apenas os registros cujo orçamento fosse superior a zero (Figura 17).

Na Figura 18 tem-se a visualização dos dados de orçamento, considerando os campos decade (eixo X) e average_budget (eixo Y). Destacando-se a década de 1990 com maior orçamento médio dos filmes de terror avaliados.




Figura 18: Visualização da evolução do orçamento médio por década.

c) Como foi a evolução da receita média por década?




Figura 19: Consulta da evolução da receita média por década.

De forma semelhante às consultas anteriores, a análise da evolução da receita média foi realizada a partir do agrupamento dos filmes por década. Para o cálculo da média, foram desconsiderados os registros que apresentavam receita igual a zero, uma vez que esses valores podem representar dados não informados ou indisponíveis. A partir desse tratamento, foi possível calcular a receita média dos filmes para cada década, permitindo analisar a evolução do desempenho de bilheteria ao longo dos diferentes períodos (Figura 19).

Na Figura 20 tem-se a visualização dos resultados da consulta de forma gráfica. Observa-se que a década de 1970 apresenta a maior média de receita entre os períodos analisados. Também é possível identificar uma tendência de crescimento da receita média entre as décadas de 1990 e 2010, seguida por uma redução na década de 2020.




Figura 20: Visualização da evolução da receita média por década.

De forma geral, as consultas desenvolvidas permitiram analisar diferentes aspectos do desempenho dos filmes de terror, considerando indicadores de popularidade, avaliação dos usuários, orçamento, receita média e quantidade de lançamentos ao longo das décadas. A combinação desses indicadores possibilita uma visão mais ampla da evolução do gênero na base de dados, permitindo identificar variações na produção, no investimento, no desempenho de bilheteria e na percepção do público ao longo do período analisado.

7. Autoavaliação

A partir das análises realizadas, foi possível responder de forma satisfatória às questões levantadas. Os resultados obtidos permitiram explorar diferentes aspectos dos filmes de terror, proporcionando uma visão geral sobre sua popularidade, avaliação, orçamento, receita e evolução da quantidade de lançamentos ao longo das décadas. Além dos resultados analíticos, o desenvolvimento das consultas contribuiu para o aprimoramento dos conhecimentos na aplicação de SQL e PySpark para exploração, transformação e análise de dados.

A principal dificuldade encontrada durante o desenvolvimento do projeto esteve relacionada à compreensão e à utilização da plataforma Databricks. Inicialmente, houve dificuldades para identificar os recursos disponíveis, devido à grande quantidade de funcionalidades oferecidas, bem como para compreender a estrutura de organização da plataforma, incluindo a localização dos arquivos, a organização dos notebooks e os procedimentos necessários para sua execução.

Essas limitações foram gradualmente superadas por meio da pesquisa em materiais disponibilizados pela própria plataforma, de conteúdos e vídeos técnicos disponíveis no YouTube e da participação nas aulas de dúvidas do MVP, que contribuíram para o esclarecimento das funcionalidades e dos procedimentos utilizados ao longo do projeto.

Foi possível identificar que alguns registros relacionados ao orçamento e à receita dos filmes apresentam valores iguais a zero, o que pode indicar a ausência dessas informações na fonte de dados, com os valores possivelmente preenchidos como zero. Essa característica pode gerar interpretações equivocadas durante as análises e representa uma limitação do conjunto de dados utilizado. Em etapas futuras, seria possível aprimorar o tratamento desses registros, seja por meio da exclusão dos valores não informados, seja pela utilização de fontes de dados complementares para obtenção dessas informações. Além disso, poderiam ser desenvolvidas consultas mais complexas, relacionando variáveis como orçamento, receita e avaliação dos filmes, de forma a investigar possíveis relações entre o investimento realizado, o desempenho financeiro e a percepção do público.

De forma geral, o desenvolvimento do trabalho foi uma experiência relevante para o aprimoramento dos conhecimentos na área de Engenharia de Dados. Apesar dos desafios encontrados ao longo do projeto, foi possível consolidar conceitos abordados na disciplina, além de adquirir experiência prática com novas ferramentas e tecnologias.